

Лекция 10

# Spark Streaming. MLlib.

Клюкин Денис

# Batch vs Stream processing



- MapReduce и Spark хорошо подходят для пакетной обработки данных.
- Иногда бывает потребность обрабатывать бесконечные потоки данных.


окна


Интернет Картинки Видео Приложения Новости Обсуждения Ответы

**REHAU окна. Купите выгодно!** Реклама  
okna.hobbit.ru Москва  
Качественные окна Rehau! Гарантийное обслуживание в подарок! Звоните!  
Двухстворчатые окна Трехстворчатые окна Балконные Блоки

**Окна**  
пластика-окон.рф  
Цены снижены на 50%. Окна. Торопитесь позвонить, время акции ограничено!  
Цены на окна Цены на остекление балконов Цены на балконные блоки

**Акция -40% от цены окна**  
oknaprosvet.ru  
Только до 30 ноября! Окна с завода со скидкой 40%. Производство 5 дней!







# Stream processing используя batch



- Можно использовать метод скользящего окна
- Hadoop MapReduce плохо подходит для real-time

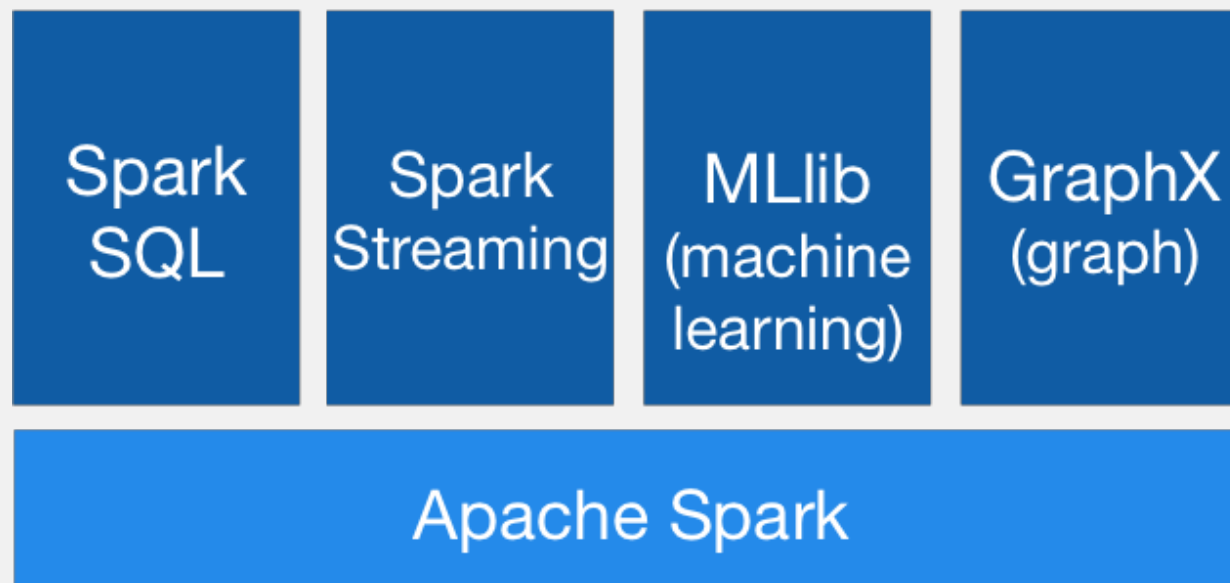




# Spark Streaming




- Масштабируемый
- Подходит для real-time (порядка 1 сек)
- Встроенная fault tolerance
- Можно комбинировать batch & streaming



## Mini-batch МОДЕЛЬ



- Делим входной поток на фрагменты (1 сек)
- Рассматриваем каждый фрагмент как RDD
- Выход – поток обработанных RDD



- Используем общий код для обработки данных
- Легко организовать fault tolerance
- Можно комбинировать с batch обработкой

# Discretized Streams (DStreams)



2 способа создать DStream:

1. Из входного источника
2. Применяя трансформации к другим DStream



# Receiver



- *Базовые источники:* файловая система, сокет  
`streamingContext.textFileStream(dataDirectory)`
- *Расширенные источники:* Kafka, Flume, Twitter...  
`KafkaUtils.createStream(ssc, zk, "name", {topic: 1})`
- Кастомные источники

Важно! Один приёмник расходует 1 слот!

# Кастомный Receiver



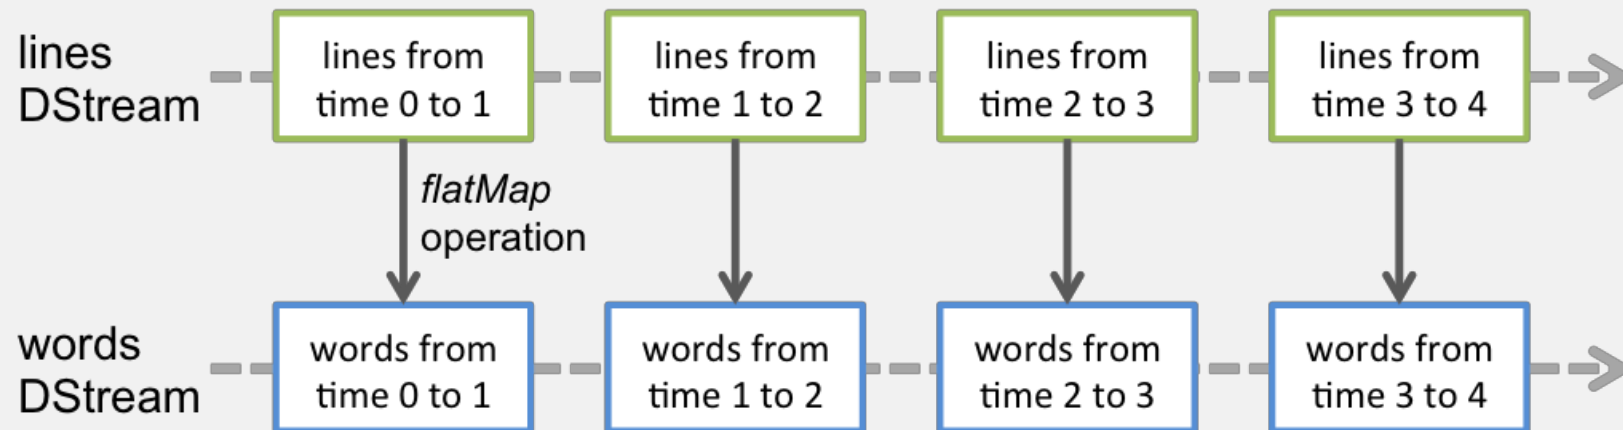
```
class MyReceiver(storageLevel: StorageLevel) extends NetworkReceiver[String](storageLevel) {  
  def onStart() {  
    // Setup stuff (start threads, open sockets, etc.) to start receiving data.  
    // Must start new thread to receive data, as onStart() must be non-blocking.  
  
    // Call store(...) in those threads to store received data into Spark's memory.  
  
    // Call stop(...), restart(...) or reportError(...) on any thread based on how  
    // different errors needs to be handled.  
  
    // See corresponding method documentation for more details  
  }  
  
  def onStop() {  
    // Cleanup stuff (stop threads, close sockets, etc.) to stop receiving data.  
  }  
}
```

- Компактное API
- Бывают 2х видов: надежные и ненадежные

# Transformations



1. Классические spark преобразования (map, reduceByKey, и т.д.) Применяются к каждому RDD индивидуально.



2. Специальные операции
  - Скользящее окно
  - Обновление состояния


# UpdateStateByKey



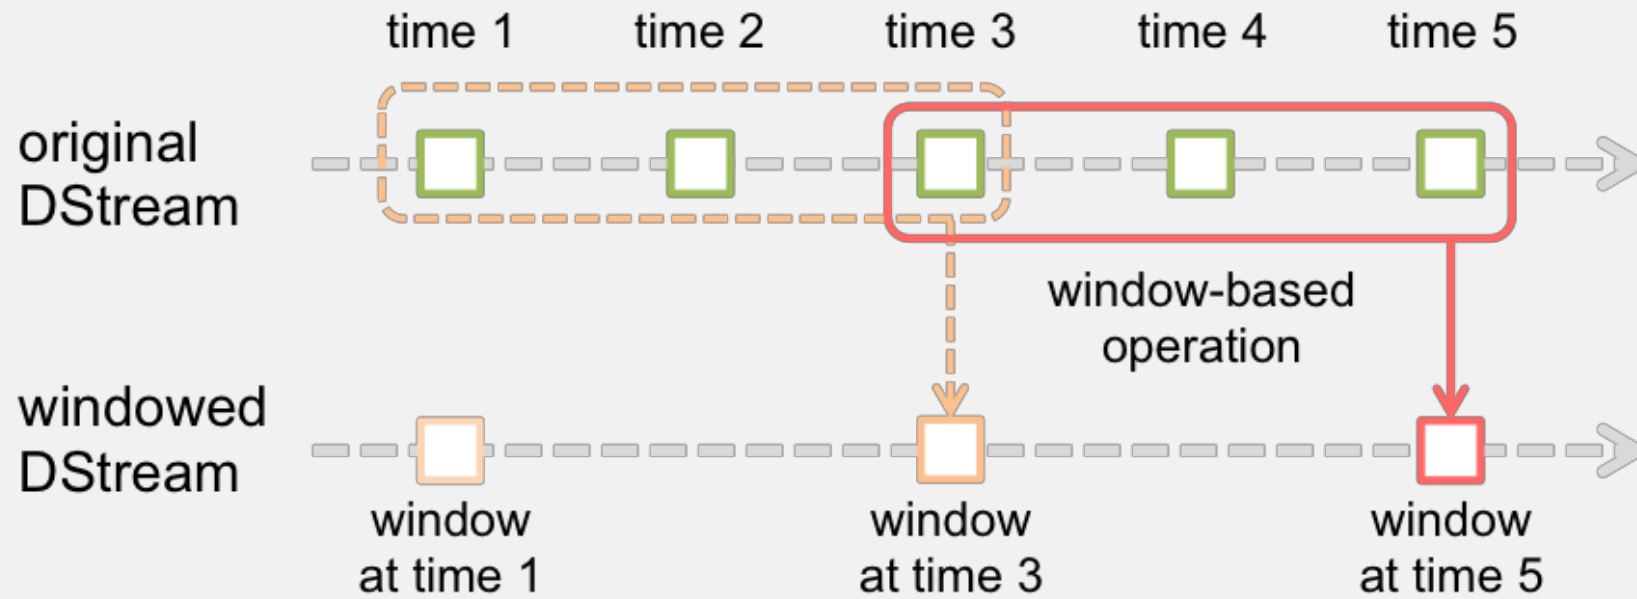
- Возможность работать с состояниями

```
def updateFunction(newValues, runningCount):  
    if runningCount is None:  
        runningCount = 0  
    return sum(newValues, runningCount)
```

```
runningCounts = pairs.updateStateByKey(updateFunction)
```



# Скользящее окно



# Скользящее окно



- `window(windowLength, slideInterval)`
- `countByWindow(windowLength, slideInterval)`
- `reduceByWindow(func, windowLength, slideInterval)`
- `reduceByKeyAndWindow(func, windowLength, slideInterval, [numTasks])`
- `reduceByKeyAndWindow(func, invFunc, windowLength, slideInterval, [numTasks])`
- `countByValueAndWindow(windowLength, slideInterval, [numTasks])`

# Сохранение данных



- `print()`
- `saveAsTextFiles(prefix, [suffix])`
- `saveAsObjectFiles(prefix, [suffix])`
- `saveAsHadoopFiles(prefix, [suffix])`
- `foreachRDD(func)`
  - Не путать с `transform(func)`

Без сохранения данных spark streaming не запустит обработку данных!

# foreachRDD



```
def sendRecord(rdd):  
    connection = createNewConnection() # executed at the driver  
    rdd.foreach(lambda record: connection.send(record))  
    connection.close()  
  
dstream.foreachRDD(sendRecord)
```



# foreachRDD



```
def sendRecord(record):  
    connection = createNewConnection()  
    connection.send(record)  
    connection.close()  
  
dstream.foreachRDD(lambda rdd: rdd.foreach(sendRecord))
```

# foreachRDD



```
def sendPartition(iter):  
    connection = createNewConnection()  
    for record in iter:  
        connection.send(record)  
    connection.close()  
  
dstream.foreachRDD(lambda rdd: rdd.foreachPartition(sendPartition))
```

# foreachRDD



```
def sendPartition(iter):  
    # ConnectionPool is a static, lazily initialized pool of connections  
    connection = ConnectionPool.getConnection()  
    for record in iter:  
        connection.send(record)  
    # return to the pool for future reuse  
    ConnectionPool.returnConnection(connection)  
  
dstream.foreachRDD(lambda rdd: rdd.foreachPartition(sendPartition))
```


# Контрольные точки



- Метаданные
- Некоторые RDD

Когда применять

- `updateStateByKey` или `reduceByKeyAndWindow` (with inverse function)
- Работа 24/7



# Контрольные точки



```
# Function to create and setup a new StreamingContext
def functionToCreateContext():
    sc = SparkContext(...) # new context
    ssc = new StreamingContext(...)
    lines = ssc.socketTextStream(...) # create DStreams
    ...
    ssc.checkpoint(checkpointDirectory) # set checkpoint directory
    return ssc

# Get StreamingContext from checkpoint data or create a new one
context = StreamingContext.getOrCreate(checkpointDirectory, functionToCreateContext)

# Do additional setup on context that needs to be done,
# irrespective of whether it is being started or restarted
context. ...

# Start the context
context.start()
context.awaitTermination()
```

# Data types

---



# Data types



- Vectors

```
from pyspark.mllib.linalg import Vectors

# Use a NumPy array as a dense vector.
dv1 = np.array([1.0, 0.0, 3.0])
# Use a Python list as a dense vector.
dv2 = [1.0, 0.0, 3.0]
# Create a SparseVector.
sv1 = Vectors.sparse(3, [0, 2], [1.0, 3.0])
```

- Labeled point

```
# Create a labeled point with a positive label and a dense feature vector.
pos = LabeledPoint(1.0, [1.0, 0.0, 3.0])
```

# Data types



- Local matrix

```
from pyspark.mllib.linalg import Matrix, Matrices
```

```
# Create a dense matrix ((1.0, 2.0), (3.0, 4.0), (5.0, 6.0))
```

```
dm2 = Matrices.dense(3, 2, [1, 2, 3, 4, 5, 6])
```

```
# Create a sparse matrix ((9.0, 0.0), (0.0, 8.0), (0.0, 6.0))
```

```
sm = Matrices.sparse(3, 2, [0, 1, 3], [0, 2, 1], [9, 6, 8])
```



# Data types



- RowMatrix

```
# Create an RDD of vectors.
```

```
rows = sc.parallelize([[1, 2, 3], [4, 5, 6], [7, 8, 9], [10, 11, 12]])
```

```
# Create a RowMatrix from an RDD of vectors.
```

```
mat = RowMatrix(rows)
```

# Data types



- CoordinateMatrix
  - Each entry is (i: Long, j: Long, value: Double)

```
entries = sc.parallelize([MatrixEntry(0, 0, 1.2), MatrixEntry(1, 0, 2.1)]  
# - or using (long, long, float) tuples:  
entries = sc.parallelize([(0, 0, 1.2), (1, 0, 2.1), (2, 1, 3.7)])  
  
# Create an CoordinateMatrix from an RDD of MatrixEntries.  
mat = CoordinateMatrix(entries)
```

# Data types



- BlockMatrix
  - Each entry is (i: Long, j: Long, value: Double)

```
# Create an RDD of sub-matrix blocks.
```

```
blocks = sc.parallelize([((0, 0), Matrices.dense(3, 2, [1, 2, 3, 4, 5, 6])),  
                        ((1, 0), Matrices.dense(3, 2, [7, 8, 9, 10, 11, 12]))])
```

```
# Create a BlockMatrix from an RDD of sub-matrix blocks.
```

```
mat = BlockMatrix(blocks, 3, 2)
```



- Classification: logistic regression, naive Bayes,...
- Regression: generalized linear regression, isotonic regression,...
- Decision trees, random forests, and gradient-boosted trees
- Recommendation: alternating least squares (ALS)
- Clustering: K-means, Gaussian mixtures (GMMs),...
- Topic modeling: latent Dirichlet allocation (LDA)
- Feature transformations: standardization, normalization, hashing,...
- Model evaluation and hyper-parameter tuning
- Frequent itemset and sequential pattern mining: FP-growth, association rules, PrefixSpan
- Distributed linear algebra: singular value decomposition (SVD), principal component analysis (PCA),...
- Statistics: summary statistics, hypothesis testing,...

# Classification



```
from pyspark.mllib.classification import SVMWithSGD, SVMModel
from pyspark.mllib.regression import LabeledPoint

# Load and parse the data
def parsePoint(line):
    values = [float(x) for x in line.split(' ')]
    return LabeledPoint(values[0], values[1:])

data = sc.textFile("data/mllib/sample_svm_data.txt")
parsedData = data.map(parsePoint)

# Build the model
model = SVMWithSGD.train(parsedData, iterations=100)
```

# Classification



```
# Evaluating the model on training data
```

```
labelsAndPreds = parsedData.map(lambda p: (p.label, model.predict(p.features)))  
trainErr = labelsAndPreds.filter(lambda (v, p): v != p).count() / float(parsedData.count())  
print("Training Error = " + str(trainErr))
```

```
# Save and load model
```

```
model.save(sc, "target/tmp/pythonSVMWithSGDModel")  
sameModel = SVMModel.load(sc, "target/tmp/pythonSVMWithSGDModel")
```

# Collaborative filtering



```
from pyspark.mllib.recommendation import ALS, MatrixFactorizationModel, Rating
```

```
# Load and parse the data
```

```
data = sc.textFile("data/mllib/als/test.data")
```

```
ratings = data.map(lambda l: l.split(',')\
                    .map(lambda l: Rating(int(l[0]), int(l[1]), float(l[2]))))
```

```
# Build the recommendation model using Alternating Least Squares
```

```
rank = 10
```

```
numIterations = 10
```

```
model = ALS.train(ratings, rank, numIterations)
```

# Collaborative filtering



```
# Evaluate the model on training data
```

```
testdata = ratings.map(lambda p: (p[0], p[1]))
```

```
predictions = model.predictAll(testdata).map(lambda r: ((r[0], r[1]), r[2]))
```

```
ratesAndPreds = ratings.map(lambda r: ((r[0], r[1]), r[2])).join(predictions)
```

```
MSE = ratesAndPreds.map(lambda r: (r[1][0] - r[1][1])**2).mean()
```

```
print("Mean Squared Error = " + str(MSE))
```

```
# Save and load model
```

```
model.save(sc, "target/tmp/myCollaborativeFilter")
```

```
sameModel = MatrixFactorizationModel.load(sc, "target/tmp/myCollaborativeFilter")
```





Реализуем алгоритм PageRank

$$PR(p_i; t + 1) = \frac{1 - d}{N} + d \sum_{p_j \in M(p_i)} \frac{PR(p_j; t)}{L(p_j)},$$

Данные: LiveJournal social network

Описание <https://goo.gl/ghdIrU>

Скачать <https://goo.gl/PUhTZb>

Хадуп [/data/voropaev/soc-LiveJournal1.txt](#)



Сравниваем скорость работы алгоритма PageRank на spark и mapreduce.

Отчет:

- скорость работы двух реализаций алгоритма PageRank.
- Top-10 вершин графа
- Исходные коды

d.klyukin@corp.mail.ru



# Спасибо за внимание!

**Клюкин Денис**

d.klyukin@corp.mail.ru

Не забудьте отметитья.